

نگاشت علمی جامع تشخیص و ریشه‌یابی تنش‌های کشاورزی: تحلیل سری‌های زمانی و مدل‌های پایه

۱. تعریف فضای مسئله: از تشخیص علائم تا استنتاج علل

امنیت غذایی جهانی در دهه‌های اخیر به‌شدت تحت تأثیر تغییرات اقلیمی، نوسانات منابع آبی، افت کیفیت خاک و ظهور آفات و بیماری‌های جدید قرار گرفته است.^۱ در این بستر، پایش سلامت محصولات کشاورزی و تشخیص زودهنگام تنش‌های وارد بر آن‌ها به یکی از ارکان بی‌بدیل کشاورزی دقیق (Precision Agriculture) مبدل شده است. با این حال، در ادبیات علمی سنجش از دور (Remote Sensing) و رصد زمین (Earth Observation)، تمایز بنیادینی میان مفهوم «تشخیص تنش» (Stress Detection) و «ریشه‌یابی تنش» (Stress Attribution) وجود دارد که در بسیاری از مطالعات کلاسیک نادیده گرفته می‌شود. تشخیص تنش صرفاً به معنای شناسایی یک ناهنجاری، افت رشد یا انحراف از مسیر فنولوژیک طبیعی گیاه است؛ در حالی که ریشه‌یابی یا تفکیک (Disentanglement) تنش، فرایند غامض استنتاج علّی و تعیین دقیق عامل ایجادکننده آن ناهنجاری (نظیر کمبود آب، تنش حرارتی، کمبود مواد مغذی یا حمله عوامل بیماری‌زا) است.^۳

تنش‌های کشاورزی عموماً به دو دسته گسترده زیستی (Biotic) نظیر آفات، قارچ‌ها و علف‌های هرز، و غیرزیستی (Abiotic) نظیر خشکسالی، شوری، گرما و کمبود عناصر غذایی طبقه‌بندی می‌شوند.^۲ مسیرهای فیزیولوژیکی و بیوشیمیایی مرتبط با هر یک از این استرسورها، پاسخ‌های متفاوتی را در ساختار و متابولیسم گیاه القا می‌کنند که به سیگنال‌های قابل مشاهده در سنجش از دور ترجمه می‌شوند. به عنوان مثال، در شرایط تنش آبی یا خشکسالی، گیاه به منظور حفظ رطوبت درون‌بافتی اقدام به بستن روزنه‌های برگ (Stomatal Closure) می‌کند. این واکنش فیزیولوژیک منجر به کاهش هدایت روزنه‌ای، افت نرخ تعرق و در نتیجه توقف فرایند خنکساز تبخیری می‌شود که بازتاب آن افزایش محسوس دمای تاج‌پوش (Canopy Temperature) است.^۵ این پدیده، روزها پیش از بروز هرگونه پژمردگی ساختاری یا تغییر رنگ در برگ‌ها به وقوع می‌پیوندد. در مقابل، تنش نظیر کمبود نیتروژن مستقیماً بر بیوسنتز کلروفیل تأثیر می‌گذارد و منجر به کلروز (زردی برگ‌ها) و کاهش شدید ظرفیت جذب نور در باند‌های مرئی و لبه سرخ (Red-Edge) می‌شود، در حالی که تأثیر اولیه آن بر دمای تاج‌پوش به مراتب کمتر از تنش آبی است.^۶

چالش اساسی در سنجش از دور سنتی این است که شاخص‌های رایج مبتنی بر علائم، نظیر شاخص پوشش گیاهی تفاضلی نرمال‌شده (NDVI) یا شاخص سطح برگ (LAI)، دچار ابهام تشخیصی عمیقی هستند.^۳ افت میزان NDVI یا کاهش سطح برگ تنها نشان‌دهنده بروز آسیب است و در اغلب موارد نمی‌تواند میان تنش‌های دارای علائم طیفی مشابه تفاوت قائل شود. به عنوان مثال، کاهش سبزیگی می‌تواند ناشی از خشکسالی، کمبود نیتروژن، و یا یک بیماری ریشه‌ای کشنده نظیر پوسیدگی فیتوفترا (Phytophthora Rot) باشد.^۳ علاوه بر این، در مراحل پایانی رشد محصولات زراعی با زیست‌توده بالا نظیر سویا و ذرت، شاخص‌های طیفی اشباع شده و از ثبت سیگنال‌های ضعیف تنش عاجز می‌مانند.^۳ بر این اساس، مسئله کانونی پژوهش حاضر ارزیابی این پرسش است که چگونه می‌توان با بهره‌گیری از غنای اطلاعاتی سری‌های زمانی و ظرفیت بازنمایی مدل‌های پایه (Foundation Models)، علل تنش‌های کشاورزی را بدون اتکای صرف به مجموعه داده‌های عظیم و پرهزینه برچسب‌دار، از یکدیگر تفکیک و ریشه‌یابی کرد.

۲. ریشه‌یابی تنش در سطح شواهد: ادغام منابع اطلاعاتی چندگانه

برای گذر از پارادایم مبتنی بر تشخیص علائم به سوی ریشه‌یابی علل، ادغام و تحلیل شواهد در سطوح مختلف طیفی، حرارتی، ساختاری، فلورسانس و متغیرهای محیطی امری حیاتی است.^۸ هر یک از این منابع داده‌ای، رفتار طیفی خاصی را ثبت کرده و پنجره‌ای منحصر به فرد به سوی یکی از مکانیسم‌های فیزیولوژیک گیاه می‌گشایند.

شواهد طیفی در محدوده مرئی تا فروسرخ نزدیک (VNIR) و فروسرخ طول‌موج کوتاه (SWIR)، متداول‌ترین ابزارهای سنجش از دور کشاورزی محسوب می‌شوند. محدوده SWIR حساسیت بالایی به محتوای آب سلولی (Cellular Water Content) دارد؛ به‌طوری‌که کاهش بازتاب در این باند مستقیماً با شدت تنش آبی و دهیدراتاسیون بافت‌های گیاهی مرتبط است.^۶ در همین حال، باند‌های سبز و به‌ویژه لبه سرخ (۷۰۰ تا ۷۵۰ نانومتر) برای تشخیص تغییرات ظریف کلروفیل ناشی از کمبود نیتروژن یا مراحل اولیه عفونت‌های قارچی به کار می‌روند.^۶ با این وجود، داده‌های طیفی بازتابی اغلب نشان‌دهنده آسیب‌های از پیش رخ داده هستند. برای

تشخیص پیش‌بالینی، داده‌های حرارتی (Thermal) که از طریق حسگرهای سوار بر پهپادها یا ماهواره‌ها جمع‌آوری می‌شوند، بسیار کارآمدتر عمل می‌کنند. این داده‌ها شاخص‌هایی نظیر شاخص تنش آبی محصول (CWSI) را فراهم می‌آورند که می‌توانند تغییرات وضعیت تعرق و بسته شدن روزنه‌ها را شناسایی کرده و تنش آبی را از تنش‌های صرفاً رنگدانه‌ای تفکیک کنند.⁵

یکی از پیشرفت‌های بنیادین در ریشه‌یابی تنش‌ها، بهره‌گیری از فلورسانس القایی خورشیدی (SIF) است. SIF سیگنال نوری بسیار ضعیفی است که هنگام بازگشت مولکول‌های برانگیخته کلروفیل به حالت پایه، پس از جذب نور خورشید ساطع می‌شود.¹⁴ بر خلاف شاخص‌های بازتابی که تغییرات ساختاری و بیوشیمیایی را اندازه‌گیری می‌کنند، SIF پیوند مکانیسمی و مستقیمی با ماشین فتوسنتزی گیاه دارد.¹⁴ مطالعات نشان می‌دهد که SIF می‌تواند تنش‌های فیزیولوژیک ناشی از گرما، تجمع ازن یا خشکسالی را در مرحله فشار (Strain-phase) و بسیار زودتر از تغییر شاخص‌های ساختاری نظیر NDVI شناسایی کند.¹⁵ حداقل مقادیر SIF (SIFmin) به‌ویژه در مراحل میانی تا پایانی رشد محصول، به عنوان یکی از قوی‌ترین نشانگرها برای تفکیک تنش آبی از استرس‌های ساختاری شناخته می‌شود.¹⁵

از سوی دیگر، شواهد ساختاری حاصل از سیستم‌های لایدار (LiDAR) یا رادار دهانه ترکیبی (SAR) نقش مهمی در برآورد زیست‌توده، تراکم ساقه و تشخیص عارضه‌هایی نظیر خوابیدگی (Lodging) ایفا می‌کنند.¹⁷ با این حال، قدرتمندترین ابزار برای ریشه‌یابی دقیق تنش‌ها، ادغام متغیرهای هواشناسی و خاکی در کنار داده‌های اپتیکال است. این متغیرها به عنوان فیلترهای علی (Causal Filters) عمل می‌کنند. به عنوان مثال، بیماری‌های ریشه‌ای ناشی از رطوبت بیش از حد خاک (مانند فیتوفترا) تنها در صورت تلاقی یک شرایط فضایی ایستا، نظیر زهکشی ضعیف که توسط شاخص رطوبت توپوگرافیک (TWI) مشخص می‌شود، و یک محرک زمانی پویا نظیر بارش جمعی (AP) رخ می‌دهند.³ سیستم‌های نوین با ترکیب داده‌های چندوجهی (Multi-modal Fusion) و بهره‌گیری از حسگرهای IoT، شبکه‌ای از اطلاعات ایجاد می‌کنند که الگوهای ناهمگن و هم‌افزایی تنش‌های ترکیبی (نظیر خشکسالی همراه با تنش حرارتی) را آشکار می‌سازد.⁸

نوع داده / سنجنده	حساسیت بیوفیزیکی / فیزیولوژیکی	تنش‌های قابل تفکیک	محدودیت‌ها
طیفی (VNIR/SWIR)	رنگدانه‌ها (کلروفیل)، کاروتنوئید، ساختار سلولی، محتوای آب	کمبود نیتروژن، بیماری‌های برگ، شوری مزمن	تأخیر در بروز علائم بصری، اشباع در زیست‌توده بالا
حرارتی (Thermal)	دمای تاج‌پوش، هدایت روزنه‌ای، نرخ تعرق تبخیری	تنش آبی (خشکسالی)، تنش گرمایی اولیه	تأثیرپذیری شدید از باد و شرایط خرداقليمی
فلورسانس (SIF)	فعالیت فتوسنتزی، انتقال الکترون، کارایی نوری	تنش ازن، تنش حرارتی حاد، خشکسالی پیش‌بالینی	سیگنال بسیار ضعیف، نیازمند حسگرهای بسیار دقیق
ساختاری (SAR/LiDAR)	معماری تاج‌پوش، زوال زیست‌توده، خوابیدگی	تنش‌های فیزیکی (باد، سیل)، زوال ساختاری نهایی	عدم حساسیت به تغییرات بیوشیمیایی اولیه
هواشناسی و خاک	رطوبت در دسترس، توپوگرافی (TWI)، دمای محیط	بیماری‌های خاک‌زی (فیتوفترا)، تنش‌های اقلیمی پایه	وضوح مکانی پایین در داده‌های هواشناسی جهانی

۳. سری‌های زمانی، تشخیص زودهنگام و کشف ناهنجاری

تحلیل سری‌های زمانی (Time-Series Analysis) داده‌های سنجش از دور، سازوکاری بنیادین برای درک پویایی فنولوژیک محصولات و شناسایی انحرافات ناشی از تنش فراهم می‌آورد. از آنجا که محصولات کشاورزی دارای الگوهای رشد فصلی منحصربه‌فردی هستند، تحلیل توالی تصاویر در طول زمان نه تنها امکان تفکیک انواع گیاهان را میسر می‌سازد، بلکه اجازه می‌دهد تغییرات تدریجی سلامت محصول پیش از عبور از آستانه‌های بحرانی رصد شود.²¹

روشناسایی تحلیل سری‌های زمانی از تکنیک‌های آماری سنتی نظیر فیلترهای هموارساز گذر کرده و به معماری‌های پیشرفته یادگیری عمیق تکامل یافته است. شبکه‌های بازگشتی نظیر حافظه کوتاه‌مدت ماندگار (LSTM) توانسته‌اند وابستگی‌های زمانی را به خوبی مدل‌سازی کنند، اما ظهور معماری‌های مبتنی بر ترانسفورمر (Transformers) استانداردهای این حوزه را دگرگون ساخته است.¹⁸

ترانسفورمرهای بصری-زمانی، نظیر آنچه در مدل AgriFM به کار رفته است، با همگام‌سازی فرآیند کاهش مقیاس (Downsampling) زمانی و مکانی، وابستگی‌های دوربرد را در سری‌های زمانی طولانی و نامنظم ماهواره‌ای استخراج کرده و الگوهای چندمقیاسی فنولوژیک را بهینه‌سازی می‌کنند.²¹

در زمینه تشخیص زودهنگام (Early Detection)، هدف شناسایی علائم پیش‌بالینی پیش از بروز آسیب‌های برگشت‌ناپذیر است.⁵ نوآوری‌های اخیر در یادگیری خودنظارتی (Self-Supervised Learning) نشان داده‌اند که می‌توان بدون اتکا به داده‌های برچسب‌دار، سیر تکاملی تنش را مدل‌سازی کرد. چارچوب یادگیری تقابلی EigenCL یکی از نمونه‌های بارز این رویکرد است که با استفاده از دینامیک زمانی شاخص لیه سرخ (NDRE) عمل می‌کند.²⁸ در این روش، به جای استفاده از افزونگی‌های تصویری (Augmentations) معمول، یک ماتریس شباهت توابع پایه شعاعی (RBF) از سری‌های زمانی NDRE تشکیل شده و با استفاده از تجزیه مقادیر ویژه (Eigen Decomposition)، بردار ویژه اصلی که بیش از ۷۶ درصد واریانس زمانی را توضیح می‌دهد، استخراج می‌گردد.²⁹ این بردار ویژه به عنوان یک ناظر بیولوژیک برای هدایت یادگیری تقابلی عمل کرده و موفق شده است تنش خشکسالی را تا ۱۲ روز پیش از رسیدن شاخص‌ها به آستانه خطر، در مزارع ذرت تشخیص دهد.²⁹

از سوی دیگر، کشف ناهنجاری (Anomaly Detection) پاسخی به چالش کمبود داده‌های برچسب‌دار برای تمامی ترکیبات ممکن از تنش‌هاست. رویکردهای بدون نظارت با بهره‌گیری از رمزگذار-رمزگشاها (Autoencoders) و رمزگذارهای متغیر (VAEs)، یک فضای پنهان فشرده از الگوهای رشد طبیعی محصول ایجاد می‌کنند.²⁰ هرگونه انحراف از این فضای بازسازی‌شده، به عنوان نمره ناهنجاری ثبت می‌شود. با توجه به اینکه تنش‌های کشاورزی (نظیر گسترش یک آفت یا محدودیت رطوبت خاک) دارای همبستگی فضایی قدرتمندی هستند، استفاده از رمزگذارهای گراف (Graph Autoencoders) برای پایش استرس خاک بسیار مورد توجه قرار گرفته است. این معماری‌ها با ترکیب ساختار رابطه‌ای پیکسل‌ها و حسگرهای مجاور، ناهنجاری‌های مکانی-زمانی پیچیده را فراتر از آستانه‌های ثابت سنتی شناسایی کرده و نویزهای موضعی را فیلتر می‌کنند.²⁰

۴. مدل‌های پایه در رصد زمین (Earth Observation Foundation Models)

رئیس‌انسان نوین در سنجش از دور کشاورزی با معرفی مدل‌های پایه مکانی-فضایی (Geospatial Foundation Models) آغاز شده است.³² برخلاف مدل‌های پیشین که نیازمند مقداردهی اولیه با وزن‌های مجموعه داده ImageNet بودند، مدل‌های پایه مستقیماً بر روی آرشیوهای پتابیتی از مشاهدات زمین آموزش می‌بینند. این آموزش عموماً از طریق اهداف یادگیری خودنظارتی نظیر مدل‌سازی تصاویر پوشش‌دار (Masked Autoencoders - MAE) صورت می‌پذیرد و به شبکه اجازه می‌دهد بازتاب‌های طیفی، پویایی زمانی و ساختارهای فضایی سطح زمین را در قالب بردارهای جاسازی (Embeddings) متراکم رمزگذاری کند.³³

مدل Prithvi-EO-2.0، توسعه‌یافته توسط ائتلاف NASA و IBM، نمایانگر جهشی بزرگ در درک مکانی-زمانی است.³⁴ این مدل در نسخه‌های ۳۰۰ و ۶۰۰ میلیون پارامتری، بر روی ۴.۲ میلیون نمونه سری زمانی از آرشیو هماهنگ‌شده لندست و سنتینل-۲ (HLS) آموزش دیده است.³⁴ نوآوری بنیادین Prithvi در تعبیه رمزگذاری موقعیتی سابعیدی (۲D Positional Encoding) نهفته است که توجه فضایی و زمانی را به طور همزمان اعمال می‌کند. همچنین این مدل، فراداده‌های موقعیت جغرافیایی و زمان را به

صراحت و ارد فضای جاسازی کرده است که قابلیت تعمیم‌پذیری آن را در اکوسیستم‌های مختلف به شدت افزایش می‌دهد.⁴⁰ عملکرد Prithvi در انتقال به وظایف جدید (Few-shot adaptation) برای تخمین بازده محصول و پایش سلامت، برتری ۸ درصدی نسبت به نسخه‌های پیشین خود نشان داده است.³⁴

مدل **Clay v1.5** با بیش از ۶۳۰ میلیون پارامتر، رویکردی مستقل از حسگر (Sensor-agnostic) را اتخاذ کرده است.⁴² معماری این مدل مبتنی بر یک بلوک جاسازی پویاست که اطلاعات مربوط به طول‌موج‌های حسگرهای گوناگون (از جمله همزمان از منابع چندگانه اپتیکال و رادار، کیفیت بازنمایی فوق‌العاده‌ای در تشخیص الگوهای اکولوژیک ارائه می‌دهند که بدون نیاز به تنظیم دقیق گسترده، در قالب ویژگی‌های جدولی (Tabular Features) برای مدل‌های رگرسیون پایین‌دست قابل استفاده هستند.³⁵ در مقیاسی متفاوت، مدل **AlphaEarth Foundations (AEF)** توسعه‌یافته توسط Google DeepMind، مرزهای همگرایی چندوجهی را گسترش داده است.³⁶ AEF با تلفیق داده‌های نوری، رادار، لایدار و شبیه‌سازی‌های اقلیمی، یک میدان جاسازی ۶۴-بعدی تولید می‌کند.³⁶ نکته حائز اهمیت در AEF، استفاده از مکانیسم جاسازی کروی فون-میزس فیشر (vMF) است که ثبات معنایی بالایی در زمان و مکان ایجاد می‌کند. ارزیابی‌ها نشان داده‌اند که بردارهای AEF دارای قابلیت تفکیک‌پذیری (Separability) بی‌نظیری هستند؛ به گونه‌ای که تنها یکی از ابعاد این جاسازی‌ها (بعد A29) می‌تواند عملکردی معادل یا برتر از شاخص‌های سنتی در کلاس‌بندی مزارع تحت آبیاری از خود نشان دهد.⁴⁹

مدل‌های اختصاصی حوزه کشاورزی نظیر **AgriFM** نیز با هدف رفع محدودیت‌های مدل‌های عمومی معرفی شده‌اند.²⁴ مدل‌های عمومی اغلب از پنجره‌های زمانی و مکانی ثابتی استفاده می‌کنند که با ماهیت چندمقیاسی سیستم‌های زراعی همخوانی ندارد. AgriFM با آموزش روی ۲۵ میلیون نمونه و همگام‌سازی استخراج ویژگی‌های سلسله‌مراتبی، توانسته است هشدارهای زود هنگام تنش‌های ترکیبی (نظیر خشکسالی و گرما) را بین ۱۸ تا ۲۴ روز سریع‌تر از بیس‌لاین‌های مبتنی بر تصاویر ماهواره‌ای صرف، صادر نماید.²¹

نام مدل پایه	معماری و پارامترها	داده‌های پیش‌آموزش (Pre-training) (Data)	نوآوری اصلی در بازنمایی زمانی-فضایی	عملکرد و قابلیت تفکیک تنش
Prithvi-EO-2.0 [cite: 34, 38, 41]	ViT MAE (300M / 600M)	۴.۲ میلیون سری زمانی HLS (لندست و سنتینل-۲)	تعبیه سه‌بعدی مکان-زمان، ورودی‌های Tubelet، دریافت صریح متادیتا (طول، عرض، روز سال)	تطبیق‌پذیری بالا (Few-shot) در تخمین زیست‌توده و نقشه‌برداری محصول در اکوسیستم‌های متنوع.
Clay v1.5 cite: 42, 43, [44]	ViT-Large MAE (632M)	۷۰ میلیون قطعه تصویر جهانی (Landsat, Sentinel-1/2, NAIP, MODIS)	جاسازی پویای پیچ‌ها مشروط به طول‌موج‌های حسگر، استقلال کامل از نوع سنسور Sensor-agnostic (tic)	تولید بردارهای ۱۰۲۴-بعدی بسیار غنی که حتی در رویکرد Zero-shot برای جداسازی الگوهای فنولوژیک مؤثرند.
AlphaEarth Foundations (AEF)	Spatio-Temporal Precision Encoder	ترکیب نوری، SAR، LiDAR، اقلیم، DEM، متن	استفاده از فضای جاسازی کروی برای (vMF)	قابلیت انتقال پایدار بین‌ساله (> OA 0.87)؛ استخراج

[cite: 36, 49]			فشرده‌سازی پتابایت‌ها داده به ۶۴ بعد سازگار معنایی	مستقیم الگوهای رطوبتی بدون نیاز به محاسبه شاخص.
AgriFM [cite: 21, 22, 50]	Video Swin Transformer / Multi-modal	۲۵ میلیون نمونه از MODIS, Landsat, Sentinel-2 تحت نظارت پوشش زمین	همگام‌سازی کاهش مقیاس (Downsampling) (g) مکانی و زمانی برای حفظ ویژگی‌های فنولوژیک در مقیاس‌های گوناگون	توانایی صدور هشدار زودهنگام برای تنش‌های ترکیبی ۱۸ تا ۲۴ روز زودتر از مدل‌های معمولی.

۵. یادگیری کارآمد و قابلیت تفسیرپذیری پیشرفته (Label-Efficient Learning & Advanced XAI)

وابستگی شدید به داده‌های برجسب‌دار دقیق و گسترده، همواره به عنوان پاشنه آشیل توسعه هوش مصنوعی در کشاورزی مطرح بوده است. از این رو، استراتژی‌های یادگیری کارآمد (Label-Efficient) نظیر یادگیری خودنظارتی و یادگیری فعال (Active Learning) اهمیتی راهبردی یافته‌اند.²⁹ با این وجود، فراتر از دستیابی به دقت بالا در پیش‌بینی، ماهیت جعبه‌سیاه (Black-box) شبکه‌های عصبی عمیق مانع از ایجاد اعتماد و پیاده‌سازی این سیستم‌ها در سیاست‌گذاری‌های کلان امنیت غذایی می‌شود.⁵⁵

محدودیت‌های تفسیرپذیری کلاسیک

تکنیک‌های کلاسیک تفسیرپذیری پس‌نگر (Post-hoc XAI) نظیر SHAP، LIME و Grad-CAM، بهرغم کاربرد وسیع در تحلیل اهمیت ویژگی‌ها، دارای محدودیت‌های بنیادینی هستند. مطالعات نشان داده‌اند که این الگوریتم‌ها در برابر نویزهای موضعی ناپایدار بوده و ممکن است توضیحات متناقضی ارائه دهند.⁵⁶ در مبحث حساس ریشه‌یابی تنش، صرف مشخص کردن پیکسل‌های مؤثر بر تصمیم‌گیری مدل کفایت نمی‌کند؛ درک اینکه چرا مدل این پیکسل‌ها را نشانه‌ای از تنش گرمایی دانسته است و نه کمبود نیتروژن، مستلزم استنتاج علی است.⁷

مدل‌های گلوگاه مفهومی (Concept Bottleneck Models)

برای غلبه بر این محدودیت‌ها، نسل جدیدی از معماری‌ها تحت عنوان مدل‌های گلوگاه مفهومی (CBM) توسعه یافته‌اند. در CBM، شبکه پیش از اتخاذ تصمیم نهایی، موظف است مجموعه‌ای از مفاهیم (Concepts) قابل درک برای انسان را پیش‌بینی کند.⁵⁵ در یک پیشرفت چشمگیر در حوزه رصد زمین، مدل PG-CBM (Process-Guided Concept Bottleneck Model) این رویکرد را با قوانین بیوفیزیکی ادغام کرده است.⁵⁵ در این مدل، یادگیری مفاهیم میانی مجبور است از مکانیسم‌های علی تعریف‌شده در دامنه اکولوژی پیروی کند. به عنوان مثال، در برآورد زیست‌توده یا تحلیل ساختار تاج‌پوش، لایه گلوگاه باید به طور صریح متغیرهایی نظیر "ارتفاع تاج‌پوش"، "درصد پوشش" و "تراکم ساقه" را استخراج کرده و تصمیم نهایی را تنها به عنوان تابعی از این مفاهیم بیوفیزیکی ارائه دهد.⁵⁵ این هدایت فرایندگرا، نه تنها از یادگیری همبستگی‌های کاذب (Spurious Correlations) جلوگیری می‌کند، بلکه مقاومت مدل در برابر داده‌های خارج از توزیع (OOD) را به شدت افزایش می‌دهد.⁵⁵ به موازات آن، مدل‌هایی نظیر درخت نمونه اولیه تقابلی (CPTR) با تلفیق یادگیری تقابلی و درخت‌های تصمیم مفهومی، مسیرهای استنتاج منطقی را برای تشخیص آفات شفاف ساخته‌اند.⁶⁴

تفسیرپذیری مکانیسمی و هوش مصنوعی علی (Mechanistic Interpretability & Causal)

(XAI)

پیشرفته‌ترین افق در این حوزه، تفسیرپذیری مکانیسمی است که بر مهندسی معکوس ساختار شبکه‌های عصبی تمرکز دارد⁶⁶. با استفاده از تکنیک‌هایی نظیر رمزگذارهای خودکار تنک (Sparse Autoencoders - SAEs)، محققان قادر شده‌اند بازنمایی‌های درهم‌تنیده و چندمعنایی (Polysemantic) درون لایه‌های پنهان مدل‌های پایه را به ویژگی‌های تک‌معنایی و قابل استنتاج تجزیه کنند⁶⁶. این امر اجازه می‌دهد تا متوجه شویم شبکه‌های ترانسفورمر دقیقاً در کدام لایه‌ها مفاهیمی نظیر "اقلیم نیمه‌خشک" یا "رژیم‌های بارشی" را رمزگذاری می‌کنند⁶⁶.

در قلمرو استنتاج علی کشاورزی، مدل‌هایی نظیر شبکه دی‌کانولوشن تنش علی (CSDN) مرزهای ریشه‌یابی را جابه‌جا کرده‌اند. CSDN با ادغام صریح شاخص‌های مکانی نظیر رطوبت توپوگرافیک (TWI) و فیلترهای زمانی نظیر بارش تجمعی (AP) درون معماری یادگیری عمیق، امکان‌گذار از شناسایی علائم طیفی صرف به ریشه‌یابی فیزیکی-مکانیسمی را فراهم آورده است³. همچنین، مدل‌های مبتنی بر گراف علی نظیر SCM-GAT نشان داده‌اند که با گنجاندن روابط علت و معلولی در شبکه توجه، می‌توان پایداری پیش‌بینی‌ها را در برابر تنش‌های ناشی از تغییرات شدید آب‌وهوایی تضمین نمود⁷⁰.

۶. مجموعه داده‌ها و معیارهای ارزیابی (Datasets & Benchmarks)

توسعه الگوریتم‌های تفکیک‌گر علل تنش، نیازمند دسترسی به مجموعه‌داده‌های استاندارد، کنترل‌شده و دارای تنوع اقلیمی است. استفاده از داده‌های مشاهداتی تصادفی، خطر ایجاد سوگیری‌های جغرافیایی را به همراه دارد و ارزیابی تداخل تنش‌ها را غیرممکن می‌سازد¹⁸.

موجودی مجموعه‌داده‌ها (Dataset Inventory)

علاوه بر آرشیوهای کلان‌مورد استفاده برای آموزش مدل‌های پایه (نظیر مجموعه ۴.۲ میلیون نمونه‌ای HLS و مجموعه Major-TOM برای مدل³⁴ Clay)، در ارزیابی و کالیبراسیون مدل‌های ریشه‌یابی تنش، پایگاه‌های داده‌ای زیر از اهمیت ویژه‌ای برخوردارند:

- Crop Health and Environmental Stress Dataset:** این مجموعه حاوی بیش از ۲۱۲ هزار رکورد میدانی و سنجشی از مناطق مختلف هلند است. ترکیب منحصربه‌فرد داده‌های چندطیفی، حرارتی، حسگرهای خاکی، رطوبت، pH، ایستگاه‌های هواشناسی و فعالیت آفات، آن را به ابزاری بی‌بدیل برای مدل‌سازی اثرات متقابل و ریشه‌یابی تنش‌های ترکیبی تبدیل کرده است⁷².
- مجموعه‌داده‌های فراطیفی پهپاد (UAV Hyperspectral Datasets):** پایگاه‌های داده کنترل‌شده شامل تصاویر فراطیفی پهپادی (با تفکیک‌پذیری مکانی بسیار بالا نظیر ۰.۱ متر و ۲۰۰ باند طیفی) که در شرایط تنش‌های دست‌کاری‌شده برداشت شده‌اند. این داده‌ها امکان بررسی دقیق‌ترین واکنش‌های بیوشیمیایی گیاه در مراحل مختلف رشد را مهیا می‌سازند⁷³.

جدول خلاصه معیارهای ریشه‌یابی تنش (Stress Attribution Benchmarks)

شرایط و مقیاس Conditions & (Scale)	دقت / معیار Accuracy/Me (tric)	برچسب‌گذاری (Labels)	منابع داده (Data) (Sources)	نوع تنش (Stress) (Type)
سویا، شرایط واقعی با توپوگرافی پیچیده، تفکیک علی در سطح پیکسل.	امتیاز F1 برابر 0.978 (توسط مدل CSDN)	مشاهدات کنترل‌شده میدانی با ثبت تاریخ	Sentinel-2 (NDRE, gLAI), TWI, داده بارش تجمعی	بیماری ریشه‌ای خاک‌زنی (فیتوفترا) [cite: 3]
ذرت، تشخیص ۱۲ روز پیش از بروز	شاخص Silhouette=0.7	یادگیری بدون نظارت (Eigen)	Sentinel-2 (سری زمانی NDRE)	تنش آبی زود هنگام (Drought)

[cite: 28, 29]		decomposition (	48، پیش‌بینی 95% (k-NN)	علائم آستانه، تعمیم به سال/منطقه جدید.
کمبود نیتروژن در برابر زوال ساختاری [cite: 7]	Sentinel-2 با وضوح فوق‌العاده Super-resolution (on	شاخص میدانی NBI	ضریب تعیین $R^2 = 0.77$	گندم زمستانه، تأیید تفسیرپذیری توسط SHAP مبنی بر تأثیر غالب باندهای لبه سرخ.
بیماری‌های برگ‌گی و توکسین‌ها [cite: 53]	ماهواره چندطیفی، پهنای حرارتی، متغیرهای اقلیمی	داده‌های آزمایشگاهی آفات توکسین و مایکوتوکسین	دقت 98-99% (از مایشگاه)، $R^2 = 0.74 -$ (مزرعه)	غلات، شرایط واقعی مقیاس وسیع، هشدار احتمال گسترش بیماری‌های قارچی.
تنش ترکیبی (خشکسالی + گرما) [cite: 8, 19, 50]	چندوجهی (رادار، نوری، حرارتی، خاک، مدیریت)	شبیه‌سازهای محصول، رکوردهای شکست عملکرد	هشدار زودهنگام ۱۸ تا ۲۴ روز پیش از مدل‌های سنتی	سویا، ذرت، گندم، ارزیابی روی ۵ منطقه اقلیمی متفاوت با استفاده از مدل پایه AgriFM.
ناهنجاری‌های مکانی-زمانی خاک [cite: 20, 31]	حسگرهای درجا (IoT)، هواشناسی، سنجش از دور	شبیه‌سازی تنش تغییرات رطوبت و دما	شاخص کالیبر شده تنش خاک (SSI)	ارزیابی فضایی با شبکه‌های گراف (Graph) (Autoencoders)، مقیاس مزرعه، بدون برچسب.

۷. تحلیل شکاف و نقشه راه پژوهشی

تحلیل شکاف: چرا ریشه‌یابی از تشخیص دشوارتر است؟

بررسی جامع ادبیات نشان می‌دهد که اگرچه فناوری رصد زمین در تشخیص ناهنجاری‌ها و بروز تنش به بلوغ نسبی دست یافته، اما استنتاج و تفکیک علل همچنان یک چالش باز علمی است. هسته مرکزی این دشواری در مفهوم هم‌ارزی علی (Equifinality) در سیستم‌های بیولوژیکی و اکولوژیکی نهفته است.³ در گیاهان، چندین اختلال متابولیک متفاوت ممکن است به یک پاسخ فیزیولوژیک یا ساختاری واحد منتهی شوند. برای مثال، افت کلروفیل و کاهش شاخص‌های طیفی نظیر NDVI می‌تواند معلول کمبود نیتروژن، تنش شوری، خشکسالی مزمن و یا عفونت‌های پاتوژنی باشد.³

شبکه‌های عصبی عمیق متداول به دلیل تکیه بر یادگیری همبستگی‌های آماری (Statistical Correlations) به جای استنتاج علی، تمایل دارند بر روی ویژگی‌های بارز اما غیرمتمایزکننده هم‌گرا شوند.⁵⁵ این امر منجر به از دست رفتن قابلیت تعمیم‌پذیری مدل‌ها در مواجهه با محیط‌های جغرافیایی جدید یا هنگام وقوع تنش‌های هم‌زمان (Concurrent Stresses) می‌شود.⁸ در غیاب فیلترهای علی

مکانی-زمانی (نظیر شرایط توپوگرافیک یا پروفیل حرارتی)، بازنمایی‌های طیفی استخراج‌شده با متغیرهای مخدوش‌کننده (Confounding Variables) در هم‌آمیخته و ابهام تشخیصی ایجاد می‌کنند. بنابراین، تا زمانی که مدل‌های هوش مصنوعی صرفاً به پیکسل‌ها نگاه کنند و قوانین فیزیکی و بیولوژیکی حاکم بر محصول را درک نکنند، ریشه‌یابی تنش هدفی دست‌نیافتنی خواهد ماند.

نقشه راه پژوهشی (Research Roadmap) و توجیه استراتژیک

بر اساس دهه‌ها تجربه نظارت بر پژوهش‌های مرزهای دانش در نهادهای پیشرو، گذار از پارادایم رصد انفعالی به سوی «هوش مصنوعی علی و تفکیک‌گر» نیازمند تدوین یک مسیر ساختاریافته است. در ادامه، نقشه راه جامعی شامل عناوین تحقیقاتی در سطوح مختلف ارائه می‌گردد:

۱. موضوعات فوری برای پایان‌نامه‌های کارشناسی ارشد (MSc):

- «تشخیص ناهنجاری در سری‌های زمانی با استفاده از جاسازی‌های مدل پایه»: استخراج مستقیم بردارهای جاسازی از مدل‌هایی نظیر AlphaEarth یا Clay v1.5 و ارزیابی توانایی آن‌ها در خوشه‌بندی بدون نظارت الگوهای رشد غلات، با استفاده از الگوریتم‌های یادگیری تقابلی (الهام‌گرفته از رویکرد EigenCL)²⁹.
- «تنظیم دقیق (Fine-tuning) مدل‌های پایه برای شرایط منطقه‌ای»: بهرگیری از چارچوب ماژولار TerraTorch برای تنظیم دقیق Prithvi-EO-2.0 به منظور شناسایی زود هنگام تنش آبی در محصولات استراتژیک و ارزیابی کارایی آن با تعداد نمونه کم (Few-shot)³⁴.
- توصیه برای مطالعه: مطالعه معماری بنیادین Prithvi³⁴ و اسناد فنی Clay⁴² برای درک عمیق استخراج جاسازی‌های فضایی-زمانی.

۲. مطالعات کوتاه‌مدت با قابلیت چاپ بالا (Publishable Short-term Studies):

- «ارزیابی مقایسه‌ای کیفیت بازنمایی مدل‌های پایه در ریشه‌یابی تنش»: طراحی یک پروتکل آزمایشی صریح برای مقایسه عملکرد تفکیک‌پذیری تنش کمبود نیتروژن از تنش آبی، با استفاده از بردارهای استخراجی از SatMAE در برابر AgriFM روی یک مجموعه داده کنترل‌شده²¹.
- «تلفیق داده‌های پهنای حرارتی با شاخص‌های هواشناسی برای استنتاج علی»: پیاده‌سازی معماری شبکه CSDN بر روی داده‌های چندسنسوری مزارع برای جداسازی آماری و علی استرس ناشی از گرما و خشکسالی³.
- ۳. موضوعات پرخطر/پربازده (High-Risk / High-Reward):
 - «طراحی مدل‌های گلوگاه مفهومی هدایت‌شده با فرایند (PG-CBM) برای سنجش از دور چندوجهی»: گنجاندن مفاهیم آگروکلیماتولوژی درون یک شبکه CBM، به گونه‌ای که خروجی‌های پنهان مدل دقیقاً بازتاب‌دهنده پارامترهای فیزیکی ملموس نظیر "محتوای آب معادل برگ (EWT)" یا "فلورسانس القایی خورشیدی (SIF)" باشند⁵⁵.
 - توجیه استراتژیک: موفقیت در این حوزه، به طور رادیکال نیاز به داده‌های آموزشی حجیم را مرتفع ساخته و تفسیرپذیری مطلق و قابل دفاعی را در پیش‌بینی‌های شبکه‌های عمیق به ارمغان می‌آورد که مانع از اتخاذ تصمیمات زیان‌بار توسط سیستم‌های خودکار می‌شود.

۴. جهت‌گیری‌های کلان و بلندمدت برای مقطع دکترا (PhD):

- «تفسیرپذیری مکانیسمی در مدل‌های پایه رصد زمین»: به کارگیری تکنیک‌های نوین نظیر رمزگذارهای خودکار تنک (Sparse Autoencoders) برای تجزیه فضا‌های جاسازی پلی‌سمانتیک در مدل‌های غول‌پیکری نظیر AlphaEarth. این امر به پژوهشگران اجازه می‌دهد تا نوروها و مدارهای اختصاصی که مفاهیم اقلیمی و الگوهای تنش کشاورزی را کدگذاری می‌کنند، کشف و مهندسی معکوس نمایند⁶⁶.
- «توسعه بنیادین CropFM (مدل پایه مختص فیزیولوژی محصول)»: ایجاد یک معماری ترانسفورمر چندوجهی که فراتر از بازبازی بصری (Masked Image Modeling)، معادلات رشد بیوفیزیکی گیاه، تبدلات انرژی و روابط علی میان اقلیم، خاک و فنولوژی را به عنوان توابع زیان (Loss Functions) فیزیک‌محور درون‌سازی کند⁷⁷.
- پیمایش این نقشه راه، نویدبخش گذار از مرحله سنتی و انفعالی «نظارت بر علائم» به پارادایم تحول‌آفرین «هوش مصنوعی علی و تفکیک‌گر» است. چنین تحولی نه تنها ضامن افزایش دقت پیش‌بینی‌ها در شرایط اقلیمی متغیر است، بلکه با ارتقای سطح اعتمادپذیری و شفافیت مدل‌ها، کاربرد جدی‌سازی آن‌ها را در پلتفرم‌های کلان امنیت غذایی و کشاورزی پایدار تضمین می‌نماید.

Works cited

1. Challenges and opportunities in remote sensing-based crop monitoring: a review, https://www.researchgate.net/publication/366457035_Challenges_and_opportunities_in_remote_sensing-based_crop_monitoring_a_review
2. Spatiotemporal Monitoring of Crop Stress Using Multispectral Remote Sensing and Machine Learning in Arid Agro-Ecosystems - Research Consortium Archive, <https://rcresearcharchive.com/index.php/Journal/article/download/869/853>
3. Causal Stress Deconvolution for Precision Soybean Management: A Multi-Modal Deep Learning Approach Integrating Topography, Climate, and Biophysical Indices - Korean Journal of Remote Sensing, <https://www.kjrs.org/journal/view.html?uid=1155&vmd=Full>
4. A comprehensive review of crop stress detection: destructive, non-destructive, and ML-based approaches - Frontiers, <https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2025.1638675/full>
5. Comparative Evaluation of Ground-based, Manual, and Remote Sensing Approaches for Crop Stress Detection - Pertanika Journal, [http://www.pertanika.upm.edu.my/resources/files/Pertanika%20PAPERS/JTAS%20Vol.%2049%20\(S1\)%20Mar.%202026/01%20JTAS\(S\)-3564-2025.pdf](http://www.pertanika.upm.edu.my/resources/files/Pertanika%20PAPERS/JTAS%20Vol.%2049%20(S1)%20Mar.%202026/01%20JTAS(S)-3564-2025.pdf)
6. Detection and Predicting Plant Stress Using Remote Sensing and AI - ResearchGate, https://www.researchgate.net/publication/408605681_Detection_and_Predicting_Plant_Stress_Using_Remote_Sensing_and_AI
7. Multi-Source Feature Selection and Explainable Machine Learning Approach for Mapping Nitrogen Balance Index in Winter Wheat Based on Sentinel-2 Data - MDPI, <https://www.mdpi.com/2072-4292/17/18/3196>
8. A systematic review of multi-mode analytics for enhanced plant stress evaluation - PMC, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12076076/>
9. Machine learning-driven sensor fusion for precision agriculture: current applications and future perspectives - Emerald Publishing, <https://www.emerald.com/sr/article/doi/10.1108/SR-08-2025-0613/1340236/Machine-learning-driven-sensor-fusion-for>
10. Integration of UAV and Deep Learning for Stress Detection in Pea Fields - CropSci Publisher, <https://cropscipublisher.com/index.php/lgg/article/html/4185/>
11. UAV-based remote sensing in plant stress imagine using high-resolution thermal sensor for digital agriculture practices: a meta-review | Request PDF - ResearchGate, https://www.researchgate.net/publication/357678718_UAV-based_remote_sensing_in_plant_stress_imagine_using_high-resolution_thermal_sensor_for_digital_agriculture_practices_a_meta-review
12. Artificial Intelligence (AI) in Detection of Abiotic Stress in Plants: A Review - MDPI, <https://www.mdpi.com/1424-8220/26/4/1122>
13. How Remote Sensing Identifies Crop Diseases Early - Anvil Labs, <https://anvil.so/post/remote-sensing-identifies-crop-diseases-early>

14. Harnessing solar-induced fluorescence for on-farm agricultural research and management: recent advances and outstanding needs - ResearchGate, https://www.researchgate.net/publication/405468503_Harnessing_solar-induced_fluorescence_for_on-farm_agricultural_research_and_management_recent_advances_and_outstanding_needs
15. Utilizing Multi-Source Remote Sensing Data and the CGAN to Identify Key Drought Factors Influencing Maize Across Distinct Phenological Stages - MDPI, <https://www.mdpi.com/2072-4292/18/7/1085>
16. Mechanisms of ozone effects on plant stress in soybean across growing season: from leaf to regional perspective | Environmental Science: Processes & Impacts | The Royal Society of Chemistry, <https://pubs.rsc.org/en/content/articlehtml/2026/em/d5em00785b?page=search>
17. Advancing Soybean Yield Prediction through Remote Sensing: A Review of Spectral Imaging Applications | IntechOpen, <https://www.intechopen.com/chapters/1222900>
18. Remote sensing-based rice stress and health assessment: current and future perspectives - <https://ris.utwente.nl>, https://ris.utwente.nl/ws/portalfiles/portal/519716634/Remote_sensing-based_rice_stress_and_health_assessment_current_and_future_perspectives.pdf
19. Enhancing plant resilience under combined stress: the role of reflectance spectroscopy - RIPE project, <https://ripe.illinois.edu/ort/sites/ripe.illinois.edu/files/2026-02/eraf368.pdf>
20. Spatially-aware unsupervised anomaly detection for soil stress monitoring using graph autoencoders in precision agriculture - Frontiers, <https://www.frontiersin.org/journals/sustainable-food-systems/articles/10.3389/fsufs.2026.1847007/full>
21. (PDF) AgriFM: A Multi-source Temporal Remote Sensing Foundation Model for Agriculture Mapping - ResearchGate, https://www.researchgate.net/publication/392134634_AgriFM_A_Multi-source_Temporal_Remote_Sensing_Foundation_Model_for_Agriculture_Mapping
22. AgriFM: A Multi-source Temporal Remote Sensing Foundation Model for Crop Mapping, <https://arxiv.org/html/2505.21357v2>
23. Comprehensive Analysis of Crop Yield Prediction Using Deep Learning and Remote Sensing Techniques - Preprints.org, https://www.preprints.org/frontend/manuscript/a3d5c9c11f79f168391d781a275a0f5f/download_pub/supplementary
24. AgriFM: A Multi-source Temporal Remote Sensing Foundation Model for Agriculture Mapping - arXiv, <https://arxiv.org/html/2505.21357v3>
25. Development and evaluation of a smart crop stress monitoring and management system for applications in controlled environment - ResearchGate, https://www.researchgate.net/publication/403694811_Development_and_evaluation_of_a_smart_crop_stress_monitoring_and_management_system_for_applications_in_controlled_environment
26. Climate change impacts and adaptation strategies in coconut plantations: integrating remote sensing and real-time monitoring - Frontiers,

<https://www.frontiersin.org/journals/climate/articles/10.3389/fclim.2026.1762364/full>

27. Monitoring of Agricultural Crops by Remote Sensing in Central Europe: A Comprehensive Review - MDPI, <https://www.mdpi.com/2072-4292/18/7/1075>
28. Temporal Vegetation Index-Based Unsupervised Crop Stress Detection via Eigenvector-Guided Contrastive Learning - ResearchGate, https://www.researchgate.net/publication/392405690_Temporal_Vegetation_Index-Based_Unsupervised_Crop_Stress_Detection_via_Eigenvector-Guided_Contrastive_Learning
29. Temporal Vegetation Index-Based Unsupervised Crop Stress Detection via Eigenvector-Guided Contrastive Learning - arXiv, <https://arxiv.org/pdf/2506.03394>
30. [Literature Review] Temporal Vegetation Index-Based Unsupervised Crop Stress Detection via Eigenvector-Guided Contrastive Learning - Moonlight, <https://www.themoonlight.io/en/review/temporal-vegetation-index-based-unsupervised-crop-stress-detection-via-eigenvector-guided-contrastive-learning>
31. Spatially-aware unsupervised anomaly detection for soil stress monitoring using graph autoencoders in precision agriculture - ResearchGate, https://www.researchgate.net/publication/408407040_Spatially-aware_unsupervised_anomaly_detection_for_soil_stress_monitoring_using_graph_autoencoders_in_precision_agriculture
32. Benchmarking Geospatial Foundation Models for Agriculture Applications - arXiv, <https://arxiv.org/html/2606.29664v1>
33. Earth Observation with Remote Sensing Foundation Models in ArcGIS - Esri, <https://www.esri.com/arcgis-blog/products/arcgis-pro/geoai/earth-observation-with-remote-sensing-foundation-models-in-arcgis>
34. Prithvi-EO-2.0: A Versatile Multi-Temporal Foundation Model for Earth Observation Applications - arXiv, <https://arxiv.org/html/2412.02732v3>
35. Geospatial Foundation Models for Agricultural Machine Learning - Medium, <https://medium.com/@brian-curry-research/geospatial-foundation-models-for-agricultural-machine-learning-a3cd0169d256>
36. AlphaEarth Foundations: The Potential and Challenges of Remote Sensing Foundation Models, <https://www.dqxxkx.cn/EN/10.12082/dqxxkx.2025.250426>
37. Science Collaborations Sparking New Applications With Geospatial Foundation Models, <https://science.data.nasa.gov/learn/blog/prithvi-geospatial-model-applications>
38. Prithvi-EO-2.0: A Versatile Multi-Temporal Foundation Model for Earth Observation Applications - NASA Technical Reports Server, <https://ntrs.nasa.gov/api/citations/20240015391/downloads/RSE%20Prithvi%20Global.pdf>
39. (PDF) Prithvi-EO-2.0: A Versatile Multi-Temporal Foundation Model for Earth Observation Applications - ResearchGate, https://www.researchgate.net/publication/386455261_Prithvi-EO-20_A_Versatile_Multi-Temporal_Foundation_Model_for_Earth_Observation_Applications
40. Prithvi Model: Geospatial Foundation - Emergent Mind,

- <https://www.emergentmind.com/topics/prithvi-model>
41. README.md · ibm-nasa-geospatial/Prithvi-EO-2.0-300M-TL at adc586194efd9e4edc4a3007167a63fb57f84ab6 - Hugging Face, <https://huggingface.co/ibm-nasa-geospatial/Prithvi-EO-2.0-300M-TL/blob/adc586194efd9e4edc4a3007167a63fb57f84ab6/README.md>
 42. Pretrained Model release v1.5 — Clay Foundation Model, <https://clay-foundation.github.io/model/release-notes/specification.html>
 43. Clay Foundation Model, <https://clay-foundation.github.io/model/>
 44. Major-TOM/Core-S2L2A-249k-Clay-v1_5 · Datasets at Hugging Face, https://huggingface.co/datasets/Major-TOM/Core-S2L2A-249k-Clay-v1_5
 45. Fine-tuning Clay Foundation Model for Land Cover Segmentation - IGARSS 2025 EarthFM tutorial - Development Seed, <https://developmentseed.org/igarss25tutorial/tut3-eofm-finetune/>
 46. Embedding Vector Search and Beyond with Big Query, Earth Engine, and AlphaEarth Foundations Satellite Embeddings | by Google Earth - Medium, <https://medium.com/google-earth/embedding-vector-search-and-beyond-with-big-query-earth-engine-and-alphaearth-foundations-147135d1eeab>
 47. From Imagery to Insight: Google AlphaEarth Foundations in CARTO, <https://carto.com/blog/google-alphaearth-foundations-in-carto/>
 48. Forest Communities Mapping with AlphaEarth Embeddings, <https://gee-community-catalog.org/projects/fcm10r9/>
 49. Evaluating the Performance of AlphaEarth Foundation Embeddings for Irrigated Cropland Mapping Across Regions and Years - MDPI, <https://www.mdpi.com/2072-4292/18/7/1065>
 50. A multimodal geospatial foundation model anticipates crop stress and yield failure across climates and species - Frontiers, <https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2026.1883297/full>
 51. Implement code of paper "AgriFM: A Multi-source Temporal Remote Sensing Foundation Model for Agriculture mapping" - GitHub, <https://github.com/flyakon/AgriFM>
 52. A review of remote sensing-based crop yield estimation: machine learning techniques and environmental, algorithmic, and hardware limitations - Frontiers, <https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2026.1742689/full>
 53. AI-Augmented Systematic Review of Remote Sensing and Predictive Modelling for Mycotoxin Risk Monitoring in Cereal Crops Across Central and Balkan Europe - MDPI, <https://www.mdpi.com/2072-4292/18/13/2063>
 54. A review of deep learning based agricultural remote sensing image segmentation, <https://www.agroengineering.org/jae/article/view/1954/1457>
 55. Process-Guided Concept Bottleneck Model - arXiv, <https://arxiv.org/html/2601.10562v1>
 56. Explainable Artificial Intelligence in Smart Agriculture: A Comprehensive Review of Interpretable Remote Sensing for Sustainable Decision-Making - MDPI, <https://www.mdpi.com/2624-7402/8/7/270>

57. Graph-Integrated Multimodal Concept Bottleneck Model - arXiv, <https://arxiv.org/html/2510.00701v1>
58. Feature Attribution Stability Suite: How Stable Are Post-Hoc Attributions? - arXiv, <https://arxiv.org/html/2604.02532v1>
59. Explainable Artificial Intelligence in Smart Agriculture: A Comprehensive Review of Interpretable Remote Sensing for Sustainable Decision-Making - ResearchGate, https://www.researchgate.net/publication/408427358_Explainable_Artificial_Intelligence_in_Smart_Agriculture_A_Comprehensive_Review_of_Interpretable_Remote_Sensing_for_Sustainable_Decision-Making
60. Local-Global Aware Concept Bottleneck Models for Interpretable Image Classification, <https://www.mdpi.com/1424-8220/26/6/1833>
61. On the Concept Trustworthiness in Concept Bottleneck Models, <https://ojs.aaai.org/index.php/AAAI/article/view/30109/31958>
62. (PDF) Process-Guided Concept Bottleneck Model - ResearchGate, https://www.researchgate.net/publication/399809141_Process-Guided_Concept_Bottleneck_Model
63. Process-Guided Concept Bottleneck Model - ChatPaper, <https://chatpaper.com/paper/226682>
64. Interpretable crop pest and disease identification based on comparative concept tree - PMC, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12981449/>
65. Interpretable crop pest and disease identification based on comparative concept tree, <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0343715>
66. Mechanistic Interpretability for Mapping Ecosystem Functioning - CO Meeting Organizer, <https://meetingorganizer.copernicus.org/EGU26/EGU26-20910.html?pdf>
67. Survey on the Role of Mechanistic Interpretability in Generative AI - MDPI, <https://www.mdpi.com/2504-2289/9/8/193>
68. Geospatial Mechanistic Interpretability of Large Language Models - arXiv, <https://arxiv.org/html/2505.03368v1>
69. A synthesis of soybean yield response to controlled drainage under varying precipitation patterns in the US Midwest | Request PDF - ResearchGate, https://www.researchgate.net/publication/395150416_A_synthesis_of_soybean_yield_response_to_controlled_drainage_under_varying_precipitation_patterns_in_the_US_Midwest
70. Estimating Soybean Yields Using Causal Inference and Deep Learning Approaches With Satellite Remote Sensing Data - ResearchGate, https://www.researchgate.net/publication/382720391_Estimating_Soybean_Yields_using_Causal_Inference_and_Deep_Learning_Approaches_with_Satellite_Remote_Sensing_Data
71. Explainable AI Based Wheat Crop Monitoring Using Vegetation Indices, Machine Learning and LSTM-Based Temporal Forecasting, <https://injoere.com/index.php/injoere/article/download/1140/770/2166>
72. Crop Health and Environmental Stress Dataset - Kaggle, <https://www.kaggle.com/datasets/datasetengineer/crop-health-and-environment>

[al-stress-dataset](#)

73. UAV-HSI-Crop-Dataset,
<https://www.scidb.cn/en/detail?dataSetId=6de15e4ec9b74dacab12e29cb557f041>
74. Crop Classification using Spectral Images - TechRxiv,
<https://www.techrxiv.org/doi/pdf/10.36227/techrxiv.175281112.21680652>
75. TERRATORCH: THE GEOSPATIAL FOUNDATION MODELS TOOLKIT - arXiv,
<https://arxiv.org/pdf/2503.20563>
76. Mr. Seung-Hwan Go | Author | Department of Agricultural and Rural Engineering, Chungbuk National University, 1 Chungdae-ro, Seowon-gu, Cheongju, Chungbuk 28644, Korea - SciProfiles, <https://sciprofiles.com/profile/1683657>
77. From General to Specialized: The Need for Foundational Models in Agriculture - arXiv, <https://arxiv.org/html/2507.05390v2>
78. [2507.05390] From General to Specialized: The Need for Foundational Models in Agriculture - arXiv, <https://arxiv.org/abs/2507.05390>
79. From General to Specialized: The Need for Foundational Models in Agriculture - ResearchGate,
https://www.researchgate.net/publication/393511891_From_General_to_Specialized_The_Need_for_Foundational_Models_in_Agriculture